Universidade Federal do Rio Grande do Sul - Instituto de Informática
Departamento de Informática Aplicada - Processamento de Linguagem Natural
Prof. Dennis Giovani Balreira

Lista de Exercícios - Módulo 1

1. **(Processamento de Linguagem Natural)** O que é processamento de linguagem natural?

2. **(Subdivisões de PLN)** A área de PLN geralmente é subdividida em duas partes: compreensão e geração. Explique brevemente cada parte e apresente dois exemplos de aplicações para cada área.

3. **(Teste de Turing)** Por que não podemos afirmar que "passamos no teste de Turing" apesar de conseguirmos replicar seu experimento com sucesso?

4. **(Histórico)** Explique brevemente cada uma das "ondas" históricas de PLN apresentadas abaixo:

- Modelos baseados em regras (1950-1984)
- Modelos estatísticos (1985 - 2012)
- Word embeddings fixas + Deep learning (2013-2017)
- Word embeddings contextuais + Transformer - NLU (2018 - 2022)
- Word embeddings contextuais + Transformer - NLG (2023 - ?)

5. **(Modelos baseados em regras)** O que são modelos baseados em regras? Apresente duas desvantagens desses modelos.

6. **(Fatores de crescimento de PLN)** Cite e explique brevemente dois fatores que impulsionaram o crescimento de PLN nos últimos anos.

7. **(Dado e informação)** Qual a diferença entre dado e informação?

8. **(Tipos de dados)** Explique brevemente os três tipos de dados: (i) estruturados, (ii) semi-estruturados e (iii) não-estruturados. Qual dos tipos de dados é o mais "abundante"? Qual é o mais difícil de processar?

9. **(Níveis de conhecimento da linguagem)** Dentre os principais níveis de análise linguística, pode-se destacar a sintaxe e a semântica. Qual dos níveis apresenta um maior desafio para modelos de linguagem? Por quê?

10. **(Propriedades estatísticas dos textos)** O que diz a Lei de Zipf? Qual sua relação com stopwords?

11. **(Propriedades estatísticas dos textos)** O que diz a Lei de Heaps? É possível afirmar que, em geral, a taxa de novos termos em um texto se mantém constante?

12. **(Modelos de linguagem probabilísticos)** Em que se baseiam os modelos probabilísticos para calcular a previsão da próxima palavra?

13. **(N-gramas)** Por que modelos N-gramas podem ser vistos como um caso particular da definição geral de modelos probabilísticos? Qual a diferença para o caso geral?

14. **(N-gramas)** Qual o problema da utilização de n-gramas (considerando valores pequenos de n) para calcular dependências entre palavras neste exemplo? “O bolo que Maria fez enquanto trabalhava fora durante o período da tarde estava delicioso”.

15. **(Expressões regulares)** Explique o conceito de expressões regulares e sua importância no pré-processamento de texto?

16. **(Pré-processamento de texto)** É correto afirmar que todo texto deve passar pelas técnicas de pré-processamento estudadas em aula antes de serem utilizados para um propósito específico?

17. **(Pré-processamento de texto)** Qual estratégia é comumente utilizada para segmentação de sentenças para línguas ocidentais como o inglês e português? Por que esta estratégia nem sempre funciona para outras línguas?

18. **(Pré-processamento de texto)** Cite um exemplo de tarefa onde a remoção de *stopwords* pode acabar “atrapalhando” o desempenho do modelo no seu processamento.

19. **(Pré-processamento de texto)** Quais problemas podem ocorrer ao utilizar um stemming para as palavras “bebê” e “bebendo”?

20. **(Distância mínima de edição)** Qual a distância de Levenshtein considerando custos (1,1,2) para as operações (inserção,deleção,substituição) entre as palavras “gato” e “ratos”?

21. **(Representação textual)** Qual problema em representar caracteres por números da tabela ASCII no contexto de modelos de linguagem?

22. **(Modelos tradicionais de representação textual)** Explique brevemente o funcionamento do modelo Bag of Words (BoW). Qual problema é mitigado posteriormente por TF-IDF?

23. **(Modelos tradicionais de representação textual)** Explique brevemente os termos TF e IDF do modelo TF-IDF. Qual termo está relacionado à raridade do termo?

24. **(Modelos tradicionais de representação textual)** Considere o seguinte conjunto de três documentos:

d1: “gato e cachorro”

d2: “gato gosta de leite”

d3: “cachorro gosta de osso”

Considere as seguintes questões:

a) Apresente o vetor representando o vocabulário (monte o vetor a partir da ordem em que as palavras aparecem e não remova palavras).

b) Apresente a matriz BoW, onde linhas são documentos e colunas são palavras.

c) Apresente a matriz TF-IDF, onde linhas são documentos e colunas são palavras. A resposta final pode ficar indicada em log.

25. **(Similaridade de textos)** Como métodos baseados em distância de edição, como Levenshtein, diferem de medidas de similaridade vetorial, como distância de cosseno? Em quais casos cada um seria mais apropriado?

26. **(Similaridade de textos)** Por que mesmo utilizando a técnica de distância de cosseno para capturar similaridade dos textos, os resultados com BoW e TF-IDF não tendem a ser tão bons quanto embeddings fixas?

27. **(Aprendizado supervisionado para textos)** Por que a construção de datasets para modelos de aprendizado de máquina supervisionado geralmente são tão custosos de serem elaborados?

28. **(Aprendizado supervisionado para textos)** Caso se deseje aplicar um modelo tradicional de representação textual, como o BoW, sobre um dataset de letras de músicas, quais dos passos abaixo poderiam ser feitos sobre o texto antes da codificação e da aplicação de um algoritmo de aprendizado de máquina? Justifique.

(i) Tokenização
(ii) Remoção de pontuação
(iii) Case folding
(iv) Remoção de stopwords

29. **(Aprendizado supervisionado para textos)** Por que é dito que as probabilidades calculadas no algoritmo Naive Bayes não são “exatas” no sentido estatístico sobre todo o texto? Por que essa “falta de exatidão” não é um problema para tarefas de aprendizado de máquina?

30. **(Avaliação de modelos supervisionados)** O que é generalização em modelos de aprendizado de máquina? Como “garantir” que o modelo proposto está generalizando de forma correta?

31. **(Avaliação de modelos supervisionados)** Como geralmente é feita a divisão dos dados com holdout assumindo conjuntos de treino e teste? O que é divisão estratificada e porque devemos priorizá-la sempre que possível?

32. **(Avaliação de modelos supervisionados)** Por que a abordagem k-fold cross validation é “sempre que possível” indicada em relação à abordagem com holdout?

33. **(Avaliação de modelos supervisionados)** Qual a importância da utilização do conjunto de validação (development test set) na divisão dos dados?

34. **(Avaliação de modelos supervisionados)** Considere as imagens (A) e (B) abaixo no contexto de generalização de modelos, onde os pontos são os dados e as linhas são as funções encontradas descrevendo o comportamento destes dados.

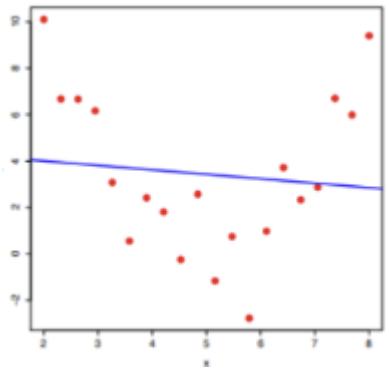

(A)

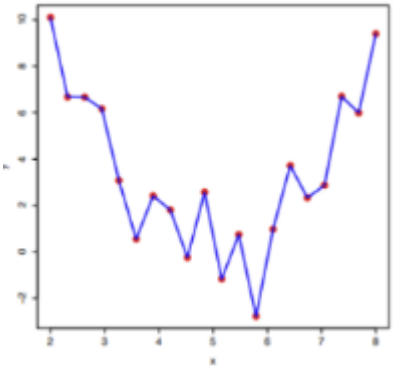

(B)

a) Quais problemas elas representam?
b) O que ocorreu com os modelos para que estes problemas tenham surgido?
c) Como seria a curva possível de “um bom modelo” que descreva estes pontos?

35. **(Avaliação de modelos supervisionados)** Por que, em geral, é mais utilizada a técnica conhecida como F1-Score para avaliação de modelos do que acurácia?

36. **(Word embeddings fixas)** Quais problemas as abordagens de representação de texto tradicionais (BoW e TF-IDF) apresentam?

37. **(Word embeddings fixas)** O que diz a hipótese distribucional? Apresente um exemplo que ilustre este processo.

38. **(Word embeddings fixas)** Considerando a afirmação “O significado de uma palavra é o seu uso na linguagem”, dada por Wittgenstein em 1953, é possível definir o significado de uma palavra sem seu contexto?

39. **(Word embeddings fixas)** Explique o conceito de word embeddings fixas e como elas diferem de representações tradicionais de texto, como Bag of Words e TF-IDF. Por que essas embeddings são consideradas mais avançadas?

40. **(Word embeddings fixas)** Quais são as principais limitações das word embeddings fixas na representação de palavras em diferentes contextos? Como essas limitações podem impactar aplicações em PLN?

41. **(Word embeddings fixas)** Explique como o treinamento de embeddings como Word2Vec utiliza grandes corpora de texto. Qual é o impacto do tamanho e da diversidade do corpus na qualidade das embeddings geradas?

42. **(Word embeddings fixas)** Qual a ideia geral do algoritmo Word2Vec (skip-gram)? Quais valores da rede neural são usados como embeddings finais para cada palavra?

43. **(Word embeddings fixas)** Por que embeddings fixas possuem muitas vezes vieses e estereótipos “maldosos”?

44. (Word embeddings fixas) Word embeddings fixas são “estáticas” no sentido de que cada palavra possui apenas uma representação vetorial, independentemente do contexto. Explique por que isso é uma limitação e como embeddings contextuais superam esse problema.

45. (Redes neurais para textos) Explique brevemente o que são modelos de redes neurais e como estes modelos em suas versões “base” podem ser utilizados com textos.

46. (Redes neurais para textos) Defina brevemente os seguintes conceitos sobre redes neurais:

a) Perceptrons, pesos e bias
b) Camadas de entrada, ocultas e de saída
c) Função de ativação (activation function)
d) Função de perda (loss function)
e) Gradiente descendente
f) Backpropagation
g) Deep learning

47. (Redes neurais para textos) Considere uma rede neural simples com as seguintes informações e estrutura:

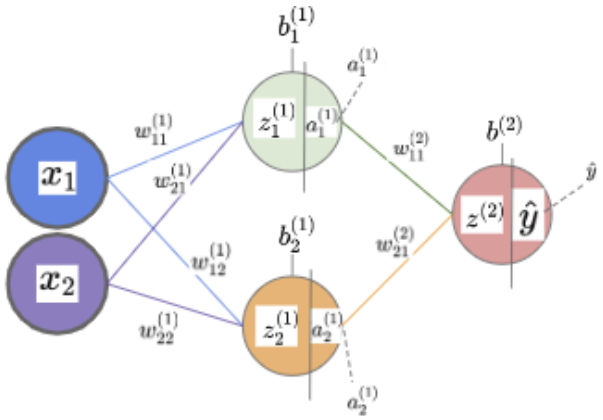

Entradas (x_1, x_2): Representam os valores fornecidos à rede como dados de entrada.

Pesos ($w_{ij}^{(1)}$, $w_{ij}^{(2)}$):

- $w_{ij}^{(1)}$: Pesos conectando as entradas (x_1, x_2) aos neurônios da camada oculta.
- $w_{ij}^{(2)}$: Pesos conectando os neurônios da camada oculta ($a_1^{(1)}$, $a_2^{(1)}$) ao neurônio de saída.

Bias ($b_1^{(1)}$, $b_2^{(1)}$, $b^{(2)}$):

- $b_1^{(1)}$, $b_2^{(1)}$: Bias adicionados à entrada dos neurônios da camada oculta.
- $b^{(2)}$: Bias adicionado à entrada do neurônio da camada de saída.

Camada Oculta ($z_1^{(1)}$, $z_2^{(1)}$): Representam os valores intermediários calculados para os neurônios da camada oculta antes de aplicar a função de ativação.

Ativações Ocultas ($a_1^{(1)}$, $a_2^{(1)}$): Saídas dos neurônios da camada oculta após a aplicação da função de ativação (ReLU, neste caso).

Camada de Saída ($z^{(2)}$): Valor calculado no neurônio da camada de saída antes da aplicação da função de ativação.

Saída ($\hat{y}$): Predição final da rede neural após a função de ativação ser aplicada no neurônio de saída.

1. **Entradas:**
   $x_1 = 2.0$ e $x_2 = -1.0$
2. **Pesos iniciais (da camada de entrada para a camada oculta):**
   - $w_{11}^{(1)} = 0.5, w_{12}^{(1)} = -0.3$
   - $w_{21}^{(1)} = 0.8, w_{22}^{(1)} = -0.7$
3. **Pesos iniciais (da camada oculta para a camada de saída):**
   - $w_{11}^{(2)} = 0.2, w_{21}^{(2)} = -0.5$
4. **Biases:**
   - $b_1^{(1)} = 0.1, b_2^{(1)} = 0.2$ (para os neurônios da camada oculta)
   - $b^{(2)} = -0.1$ (para o neurônio de saída)
5. **Função de ativação:** ReLU ($f(x) = \max(0, x)$)
6. **Função de perda:** MAE (Erro Absoluto Médio):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^{n} |y_{\text{target}} - y_{\text{predito}}|$$

O alvo da rede é $y_{\text{target}} = 1.5$.

Assumindo os valores iniciais fornecidos acima, calcule os valores intermediários dos neurônios da camada oculta (a1(1) e a2(1)), da camada final (ŷ), e o erro gerado durante a primeira passada na rede feedforward.

48. (Redes neurais para textos) Defina brevemente os seguintes conceitos sobre redes neurais textuais:

a) RNN
b) LSTM
c) Bi-LSTM
d) Encoder-decoder
e) Attention e self-attention
f) Transformers

49. (Redes neurais para textos) Discorra brevemente sobre os seguintes problemas de RNN e como eles podem ser resolvidos ou mitigados:

a) Desaparecimento e explosão de gradientes
b) Dificuldade em aprender dependências de longo prazo
c) Treinamento lento (sequencial)

50. (Redes neurais para textos) Apresente modelos de linguagens conhecidos que ilustrem o uso de arquiteturas Transformer e suas respectivas principais tarefas:

a) encoder-decoder
b) encoder-only
c) decoder-only

51. (Redes neurais para textos) Qual a ideia geral do mecanismo de atenção, com ênfase em self-attention?

52. **(Redes neurais para textos)** Por que a arquitetura Transformers possibilitou que uma quantidade enorme de dados fosse treinada em relação à arquiteturas prévias, como RNNs ou LSTMs?

53. **(Word embeddings contextuais)** Por que word embeddings contextuais conseguem lidar bem com polissemia (palavra com vários significados)? Qual a diferença principal em relação a word embeddings fixas? Apresente um breve exemplo.

54. **(*Large Language Models*)** Não há um "consenso" na comunidade com relação à classificação de modelos como LLMs. Entretanto, assumindo a definição vista em aula de que LLMs são "redes neurais profundas treinadas em quantidades massivas de dados que implementam embeddings contextuais", podemos considerar que todas LLMs são baseadas em transformers?

55. **(Word embeddings contextuais)** O processo geral de treinamento de LLMs pode ser dividido em quatro fases: (1) coleta de dados, (2) pré-processamento (tokenização), (3) pré-treino e (4) *fine-tuning*. Explique brevemente cada uma destas fases tendo enfoque nos seguintes modelos estudados:

(a) BERT

(b) GPT-3

56. **(Word embeddings contextuais)** Qual papel a arquitetura Transformer exerce sobre o tipo de aplicação que os modelos exercem? Assumindo unicamente esta característica, quais camadas Transformer (encoder-decoder, encoder, decoder) tendem a apresentar melhores resultados para as tarefas: (1) tradução automática, (2) classificação, (3) análise de sentimentos, (4) geração de texto, (5) sumarização.

57. **(Large Language Models)** Por que LLMs como o BERT e GPT podem ser treinados de forma "auto-supervisionada"?

58. **(Tokenização)** Qual o principal objetivo da utilização de estratégias de tokenização específicas para LLMs, como a Byte Pair Encoding (BPE) e WordPiece, por exemplo, em relação à técnicas tradicionais, como segmentação de palavras por espaçamentos?

59. **(BERT)** O pré-treino do modelo BERT é feito com base em duas tarefas principais: (i) Masked Language Modeling (MLM) e (ii) Next Sentence Prediction (NSP). Explique brevemente a ideia geral de cada uma delas.

60. **(BERT)** Qual a saída do modelo BERT após o pré-treino? Como esta saída pode ser adaptada para realizar tarefas específicas, como classificação, por exemplo?

61. **(Transfer learning)** Com relação à técnicas de transfer learning, explique brevemente os conceitos:

a) Pré-treino

b) Continuação de pré-treino

c) Fine-tuning

62. **(Geração de texto)** Cite e explique brevemente dois motivos que tornam o modelo BERT “pouco adequado” para tarefas de geração de texto e fins.

63. **(Geração de texto)** Qual a ideia geral de modelos de geração de texto autorregressivos, usado pela família de modelos GPT? No que atuam as estratégias de decodificação?

64. **(GPT)** Qual a intuição geral para o modelo GPT-3 ser unidirecional, em vez de bidirecional, como o modelo BERT? Qual a ideia geral do mecanismo “Masked Self Attention” nesta parte (ou seja, quais partes foram mascaradas)?

65. **(Aprendizado com poucos dados)** Por que é interessante utilizar abordagens alternativas ao “*fine-tuning*” para LLMs generativas?

66. **(Aprendizado com poucos dados)** No que consiste as abordagens zero-shot e few-shot learning?

67. **(Aprendizado com poucos dados)** Fale brevemente sobre os seguintes problemas de LLMs generativas:

a) “Papagaios estocásticos”
b) Halucinações
c) Raciocínio

Bom Trabalho**!**