UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
Instituto de Informática
Departamento de Informática Aplicada

Aula 12: Redes neurais para textos [3]

Prof. Dennis Giovani Balreira

UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

INF01221 - Tópicos Especiais em Computação XXXVI:
Processamento de Linguagem Natural

.inf
INSTITUTO DE INFORMÁTICA
UFRGS

Conteúdo

- Redes neurais para textos [3]
  - Transformer

Onde estamos em PLN?

- Algoritmos tradicionais
  - Predominantes entre o final dos anos 1990 até ~2016
  - BoW features + Aprendizado de Máquina

- Embeddings fixas + Deep Learning
  - Predominates de ~2014 até ~2019
  - Word2vec, Glove, FastText + LSTM

- Embeddings contextuais + Large Language Models
  - Estado da arte em diversas tarefas
  - BERT, GPT, etc.

Onde estamos em PLN?

- Para chegar nos modelos de linguagem de larga escala (*Large Language Models* - **LLMs**), precisamos vencer a montanha de *deep learning* para texto

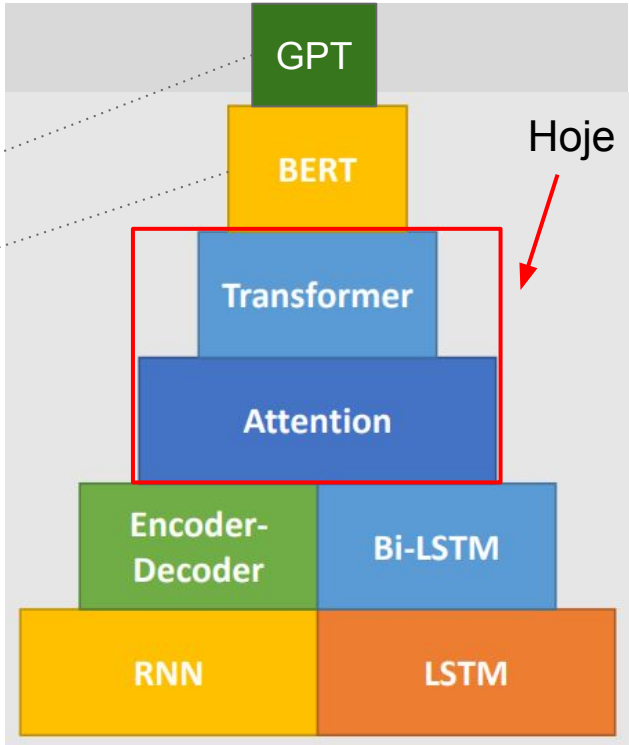

Redes Neurais: Revisão

- Modelos computacionais inspirados na estrutura e funcionamento do cérebro humano

- Redes shallow vs. deep:
  - Redes mais profundas têm melhor desempenho que redes superficiais
    - Mas apenas até certo limite
    - Após X camadas, o desempenho “estabiliza”

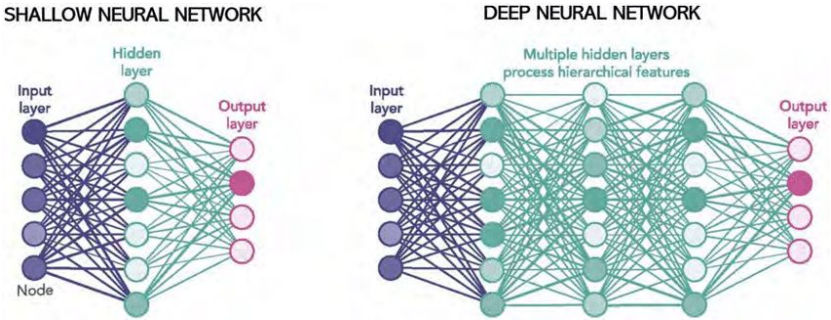

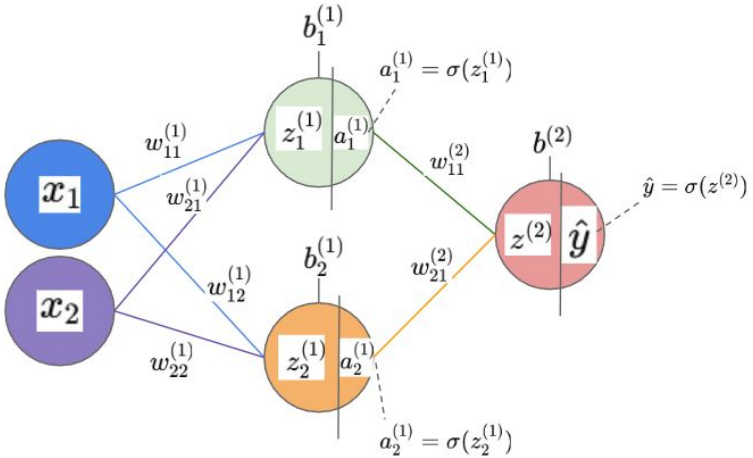

Função de ativação: $\sigma(z)$

Saída esperada: **y**

Redes Neurais para textos

- Redes neurais para textos e dados sequenciais permitem capturar padrões e estruturas complexas a partir do contexto e sequência dos dados

- As seguintes arquiteturas são especializadas para texto e dados sequenciais:
  - Redes Neurais Recorrentes (RNN)
  - Long-short Term Memory (LSTM)
  - Bi Long-short Term Memory (Bi-LSTM)
  - Encoder-decoder
  - Transformer

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*

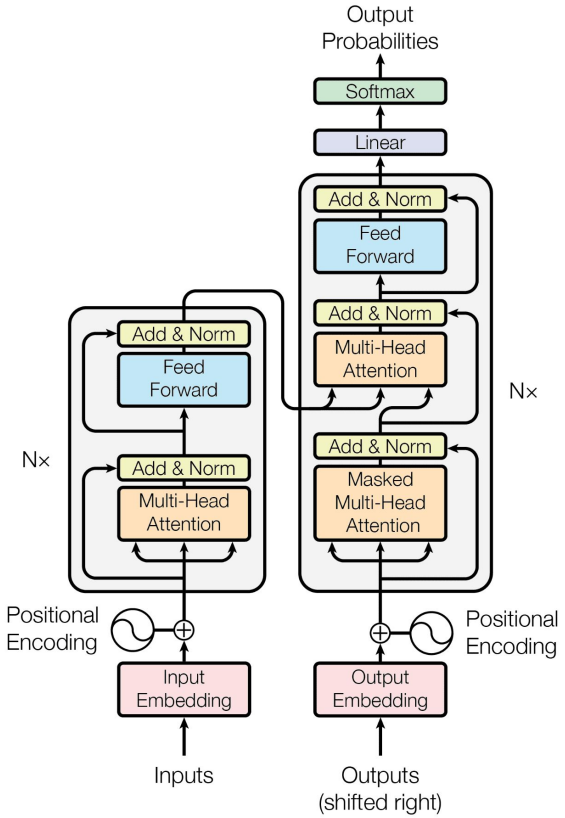

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*

Encoder:
- Transforma sequência de entrada em uma representação (embedding) contextualizada, capturando relações entre todas as palavras de entrada
- Cada token (palavra) recebe um embedding contextual próprio

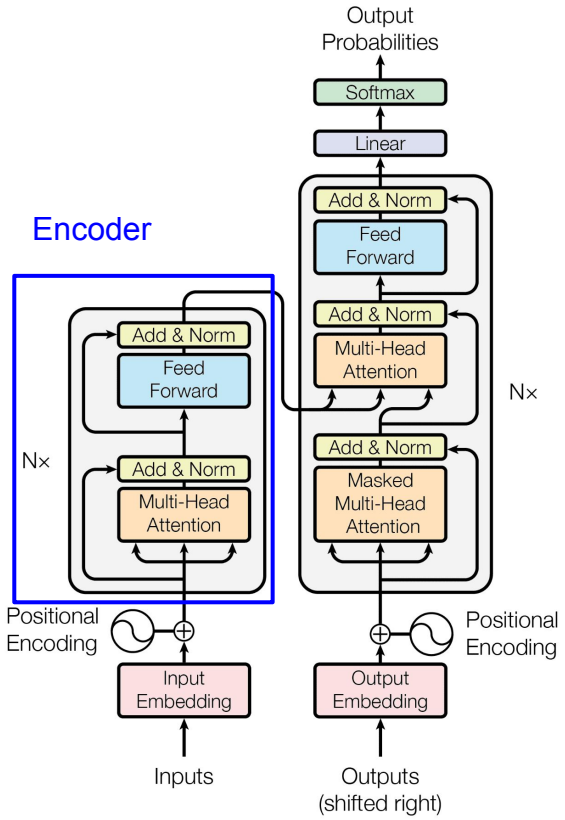

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*

Encoder:
- Transforma sequência de entrada em uma representação (embedding) contextualizada, capturando relações entre todas as palavras de entrada
- Cada token (palavra) recebe um embedding contextual próprio

Decoder:
- Gera sequência de saída token por token, usando (i) a saída do encoder e (ii) a sequência de saída gerada até o momento

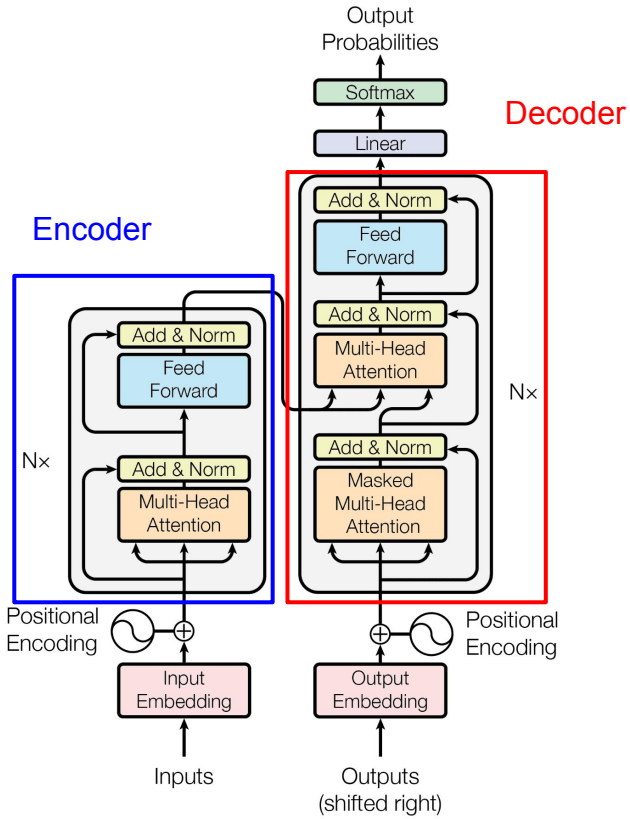

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

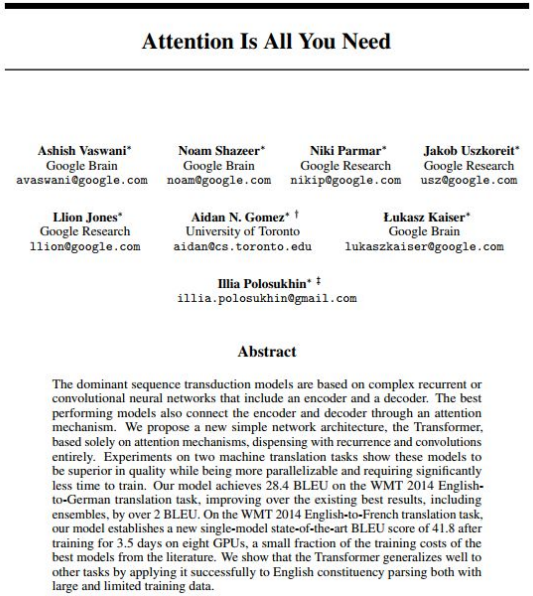

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

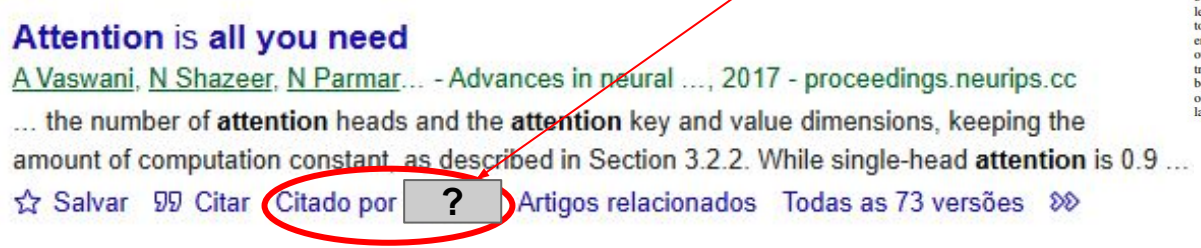

Attention is **all you need**

A Vaswani, N Shazeer, N Parmar... - Advances in neural ..., 2017 - proceedings.neurips.cc

... the number of **attention** heads and the **attention** key and value dimensions, keeping the amount of computation constant, as described in Section 3.2.2. While single-head **attention** is 0.9 ...

☆ Salvar 99 Citar Citado por ? Artigos relacionados Todas as 73 versões »

Acesso em 15/04/2025.

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

Attention is all you need

A Vaswani, N Shazeer, N Parmar... - Advances in neural ..., 2017 - proceedings.neurips.cc

... the number of **attention** heads and the **attention** key and value dimensions, keeping the amount of computation constant, as described in Section 3.2.2. While single-head **attention** is 0.9 ...

☆ Salvar 99 Citar Citado por 175987 Artigos relacionados Todas as 73 versões »

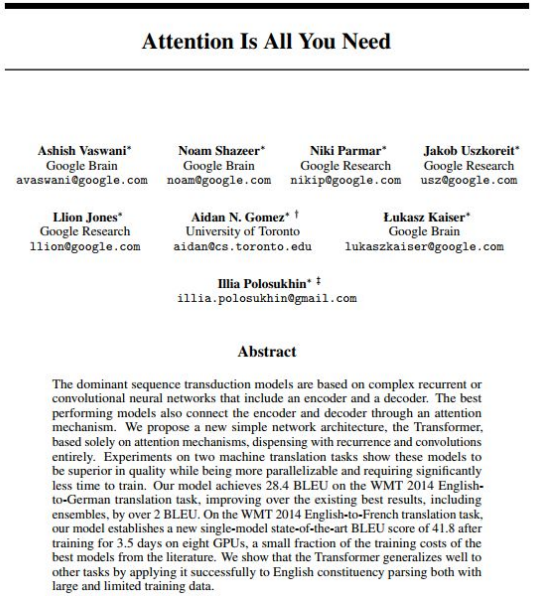

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

Acesso em 15/04/2025.

Transformer

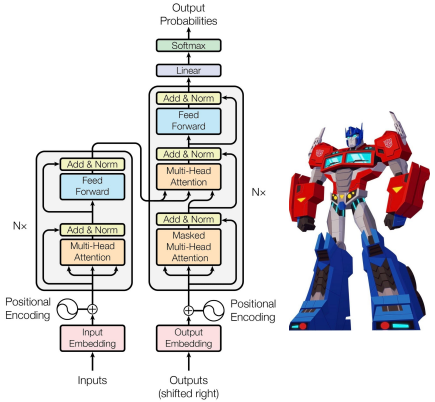

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

- Diversos modelos usam:
  - Voice-to-text

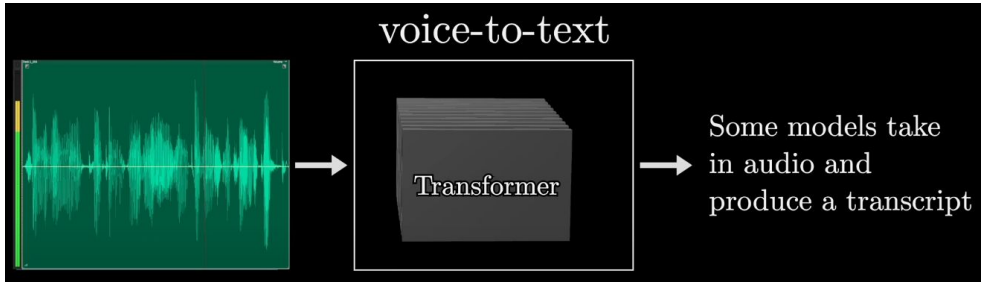

Transformer

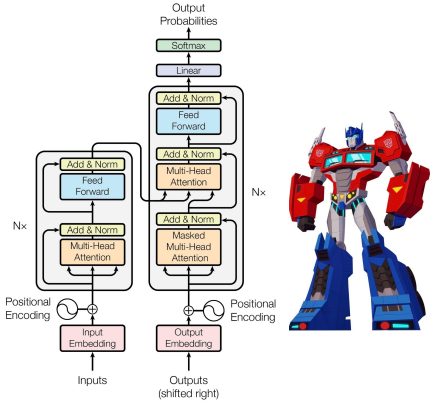

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

- Diversos modelos usam:
  - Voice-to-text
  - Text-to-voice

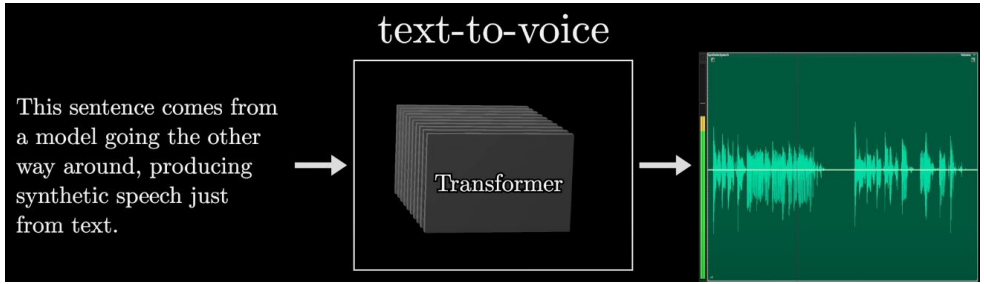

Transformer

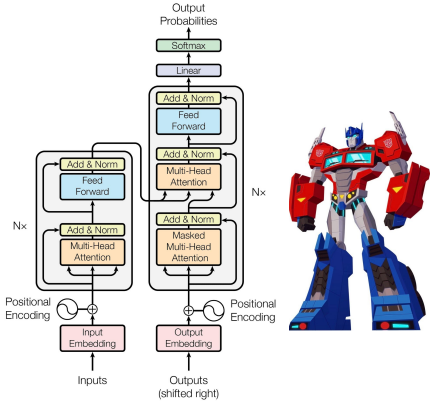

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

- Diversos modelos usam:
  - Voice-to-text
  - Text-to-voice
  - Text-to-image

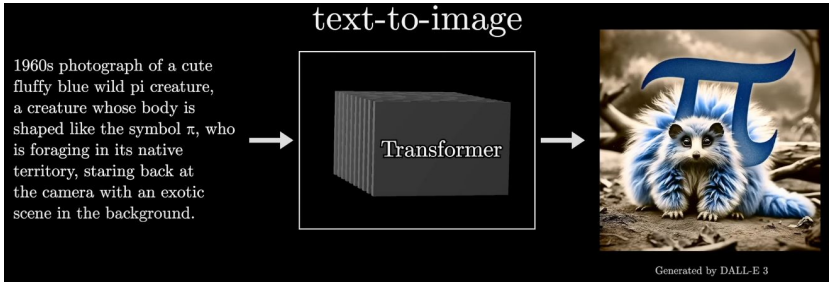

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

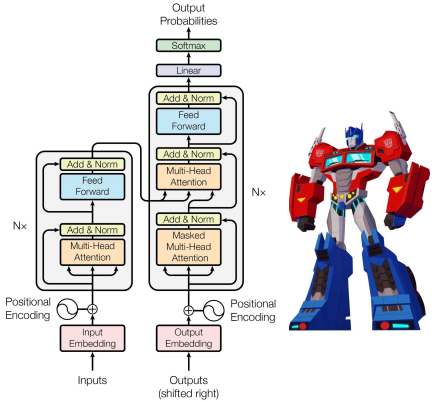

- Diversos modelos usam:
  - Voice-to-text
  - Text-to-voice
  - Text-to-image
  - Text-to-text

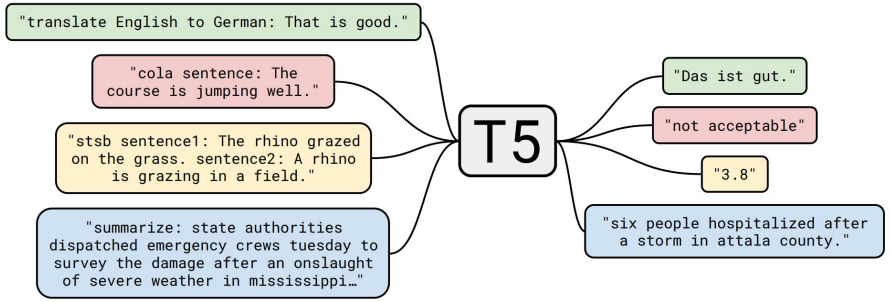

Transformer

- Arquitetura que permite processamento em paralelo utilizando encoder-decoder e mecanismo de *self-attention*
  - Apresentado no paper *Attention is all you need* (Vaswani et al. - Google, 2017)

- Diversos modelos usam:
  - Voice-to-text
  - Text-to-voice
  - Text-to-image
  - Text-to-text

- LLMs generativas: prever próxima palavra

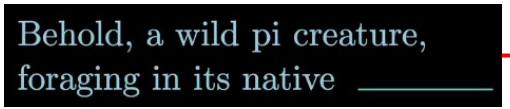

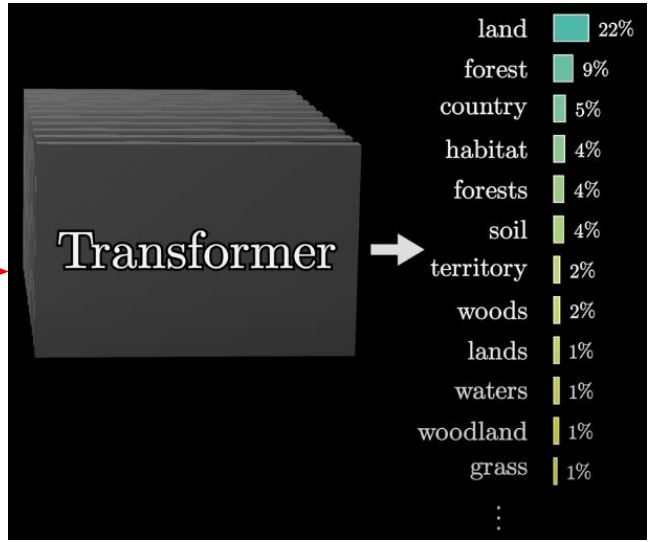

Transformer

- Resolvem dependência de longo prazo

Transformer

- Resolvem dependência de longo prazo
- Intuição: vetores de word embeddings são “adaptados” pelo contexto

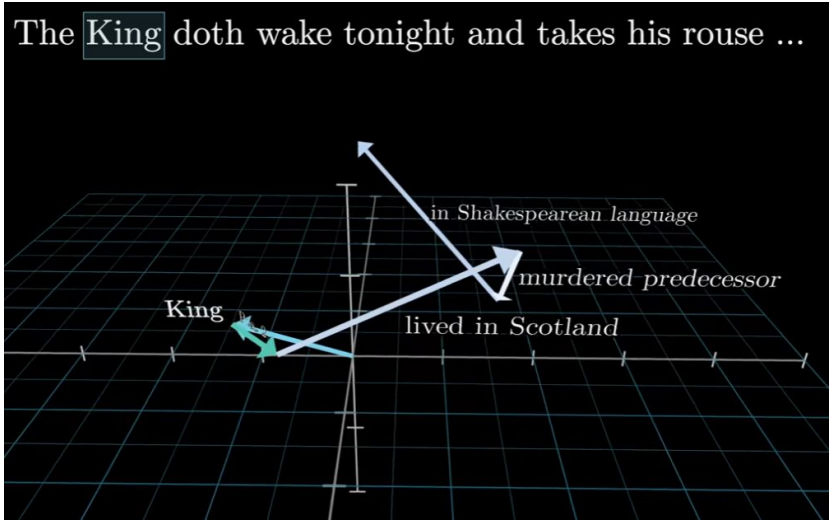

Transformer

- Originalmente, a “tarefa” visada pelo paper original foi tradução automática

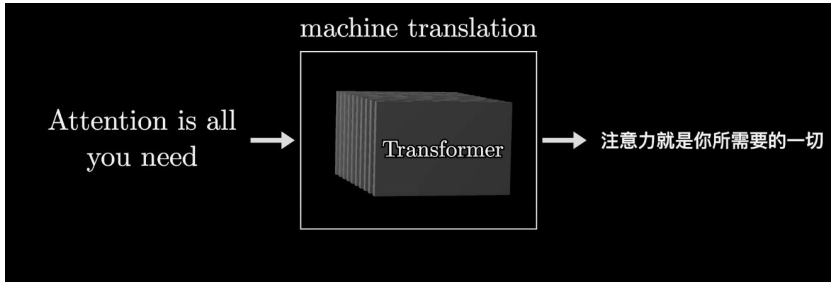

Transformer

- Originalmente, a “tarefa” visada pelo paper original foi tradução automática

- Exemplo:
  - Encoder: lado inglês
  - Decoder: lado alemão

Fonte (Inglês): "The cat sleeps on the mat."

Tradução (Alemã): "Die Katze schläft auf der Matte."

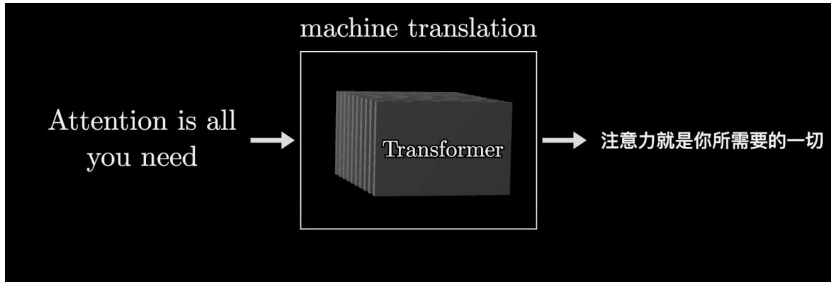

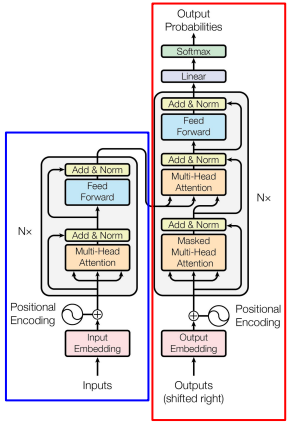

- **Datasets**:
  - **WMT 2014 English-to-German**: 4.5 milhões de pares de frases.
  - **WMT 2014 English-to-French**: 36 milhões de pares.

Transformer

- Principais pontos:
  - Input embedding
  - Positional encoding
  - Self-attention
  - Residual connections

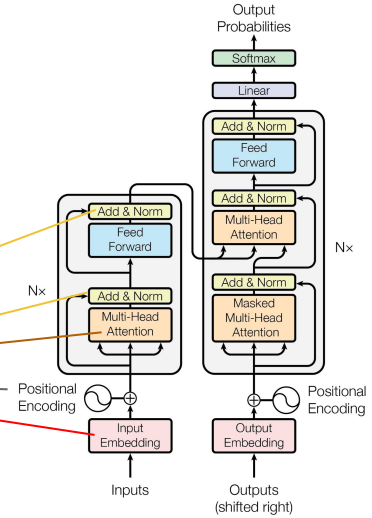

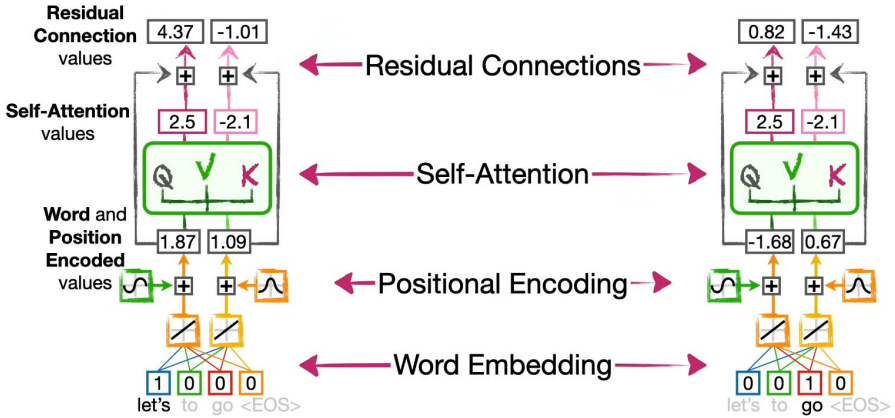

Train in parallel

Encode the relationships among the words

Encode the positions of the words

Encode words into numbers

Inputs

- Entrada do modelo como texto (frase, parágrafo, etc.)

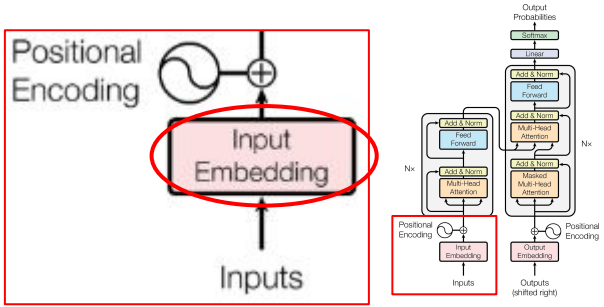

Input embedding

- Camada responsável por converter palavras (na verdade tokens) em vetores numéricos densos (embeddings)
- Cada palavra está associada a um embedding específico, iniciado aleatoriamente (mas com valo pequenos e controlados)

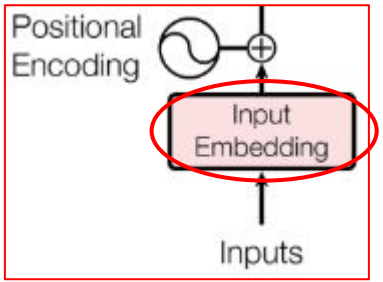

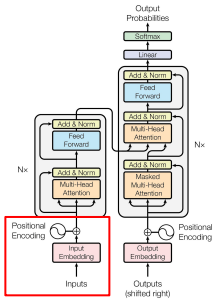

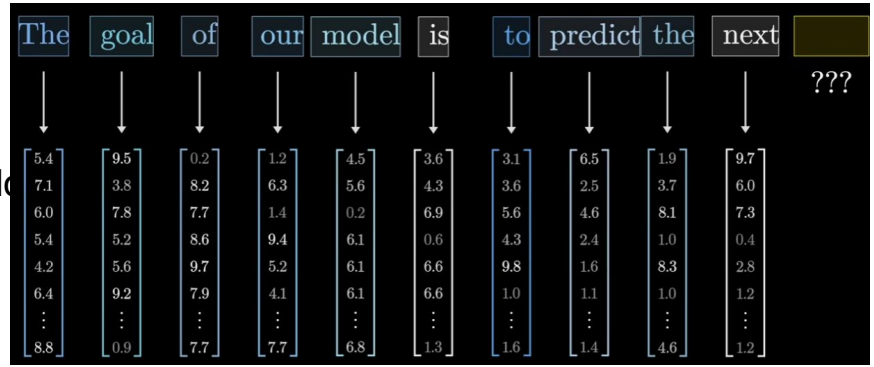

Input embedding

- Camada responsável por converter palavras (na verdade tokens) em vetores numéricos densos (embeddings)
- Cada palavra está associada a um embedding específico, iniciado aleatoriamente (mas com valo pequenos e controlados)
- É necessário prever embeddings para todas as palavras (tokens) do vocabulário

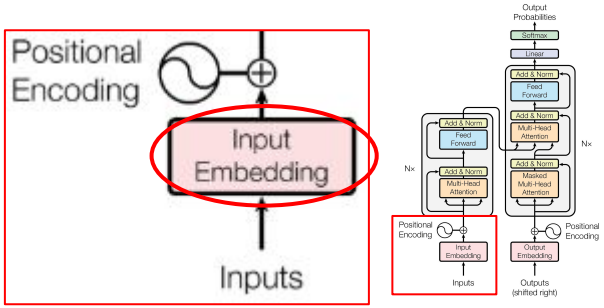

All words, ~ 50k

aalh	aardvark	aardwolf	aargh	ab	aback	abacterial	abacus	abalone	abandon	...	zygoid	zygomatic	zygomorphic	zygosis	zygote	zygotic	zyme	zymogen	zymosis	zzz
+1.0	+4.3	+2.0	+0.9	−1.5	+2.9	−1.2	+7.8	+9.2	−2.3	⋯	+0.6	+1.3	+8.4	−8.5	−8.2	−9.5	+6.6	+5.5	+7.3	+9.5
+5.9	−0.8	+5.6	−7.6	+2.8	−7.1	+8.8	+0.4	−1.7	−4.7	⋯	−0.9	+1.4	−9.5	+2.3	+2.2	+2.3	+8.8	+3.6	−2.8	−1.2
+3.9	−8.7	+3.3	+3.4	−5.7	−7.3	−3.7	−2.7	+1.4	−1.2	⋯	−7.9	−5.8	−6.7	+3.0	−4.9	−0.7	−5.1	−6.8	−7.7	+3.1
−7.2	−6.0	−2.6	+6.4	−8.0	+6.7	−8.0	+9.4	−0.6	+9.4	⋯	+4.7	−9.1	−4.3	−7.5	−4.0	−7.5	−3.6	−1.7	−8.6	+3.8
+1.3	−4.6	+0.5	−8.0	+1.5	+8.5	−3.6	+3.3	−7.3	+4.3	⋯	−6.3	+1.7	−9.5	+6.5	−9.8	+3.5	−4.6	+4.7	+9.2	−5.0
+1.5	+1.8	+1.4	−5.5	+9.0	−1.0	+6.9	+3.9	−4.0	+6.2	⋯	+7.5	+1.6	+7.6	+3.8	+4.5	+0.0	+9.0	+2.9	−1.5	+2.1
−9.5	−3.9	+3.2	−4.2	+2.3	−1.4	−7.2	−4.0	+1.4	+1.8	⋯	+3.0	+3.0	−1.4	+7.9	−2.6	−1.3	+7.8	+6.1	+4.0	−7.9
+8.3	+4.2	+9.9	−6.9	+7.3	−6.7	+2.3	−7.4	+6.9	+6.1	⋯	−1.8	−8.5	+3.9	−0.9	+4.4	+7.3	+9.4	+7.0	−9.7	−2.8
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋱	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
−3.7	−2.0	−5.7	−6.2	+8.8	+4.7	−0.2	−5.4	−4.9	−8.8	⋯	−3.7	+3.9	−2.4	−6.3	−9.4	−8.6	+3.6	−0.9	+0.7	+7.9

Input embedding

- Camada responsável por converter palavras (na verdade tokens) em vetores numéricos densos (embeddings)
- Cada palavra está associada a um embedding específico, iniciado aleatoriamente (mas com valo pequenos e controlados)
- É necessário prever embeddings para todas as palavras (tokens) do vocabulário
- Palavras usam “one-hot encoding” implícito:
  - Em vez de criar vetores esparsos, cada palavra é associada diretamente à sua posição no vetor de vocabulário

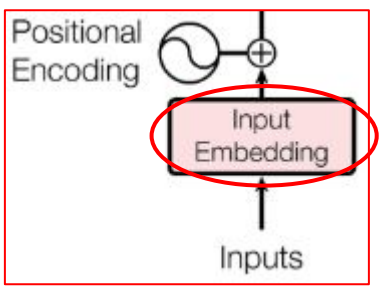

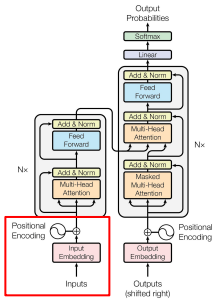

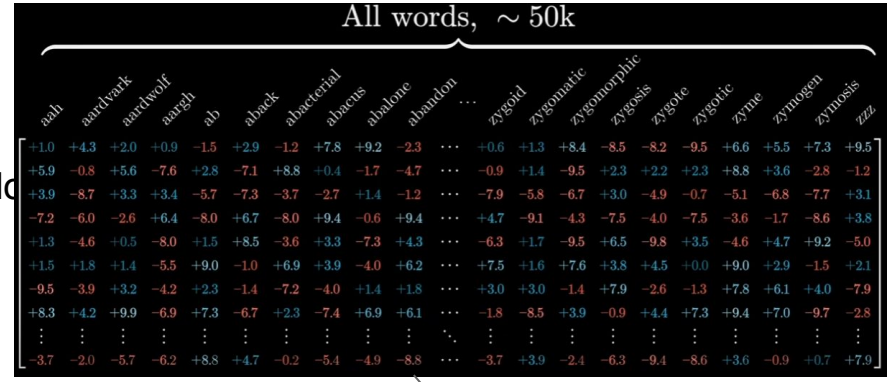

“abandon” possui ID=9

Positional encoding

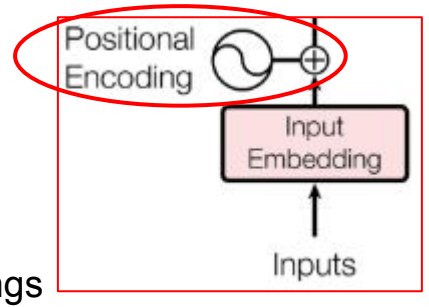

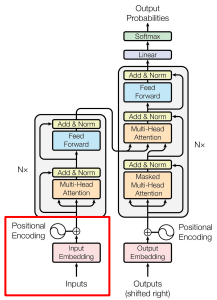

- Vetores que o Transformer adiciona aos embeddings das palavras para representar a posição de cada palavra na sequência
  - Soma de valores de funções seno e cosseno
  - Cada dimensão do embedding de cada token é somado com uma sequência de posições específicas
  - Funciona como uma espécie de “codificação” de posição única

- Os novos valores das funções são somados aos input embeddings

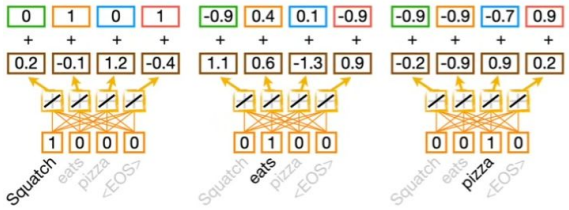

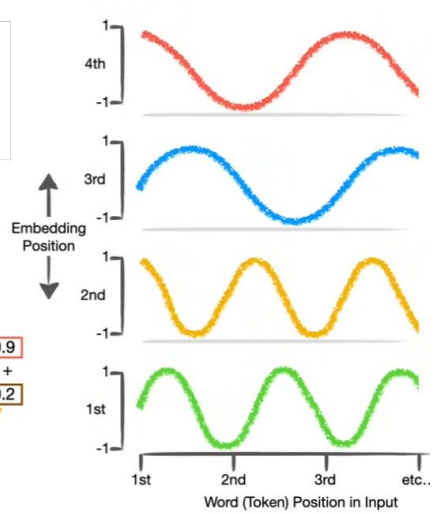

Self-attention mechanism

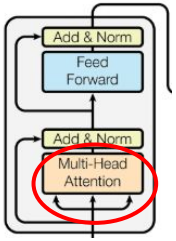

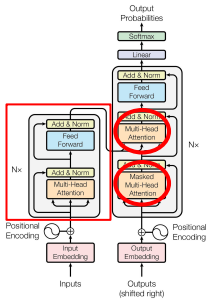

- Permite que cada elemento de uma sequência se relacione diretamente com todos os outros elementos da mesma sequência
  - O mecanismo de atenção é aplicado em todas as posições da sequência de entrada
  - Cada palavra "presta atenção" em todas as outras palavras da sequência, capturando relações de curto e longo alcance

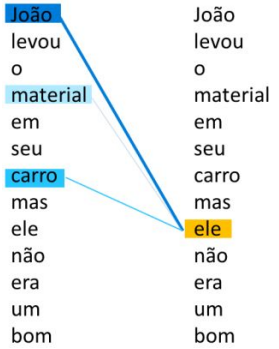

Self-attention mechanism

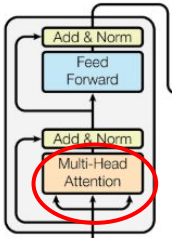

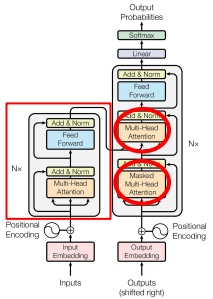

- Attention possui três componentes: Q, K e V
  - (Q)uery
  - (K)ey
  - (V)alue

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Garante que os valores sejam normalizados entre [0,1]

Dividir pela dimensão da matriz K e Q

Evita que os scores de atenção cresçam demais

Self-attention mechanism

- Attention possui três componentes: Q, K e V
  - (Q)uery: Representa a "pergunta" que um token faz sobre os outros
  - (K)ey
  - (V)alue

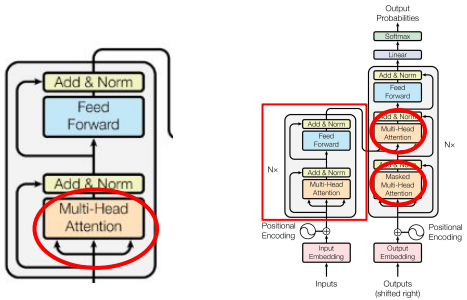

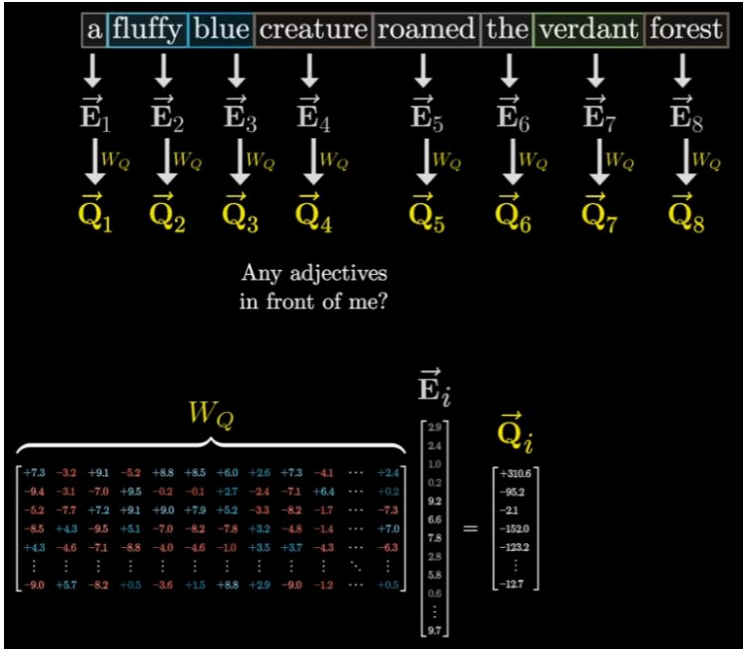

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Self-attention mechanism

- Attention possui três componentes: Q, K e V
  - (Q)uery
  - (K)ey: Representa a “chave” que um token usa para responder às queries
  - (V)alue

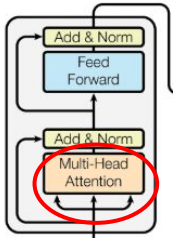

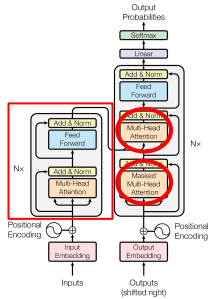

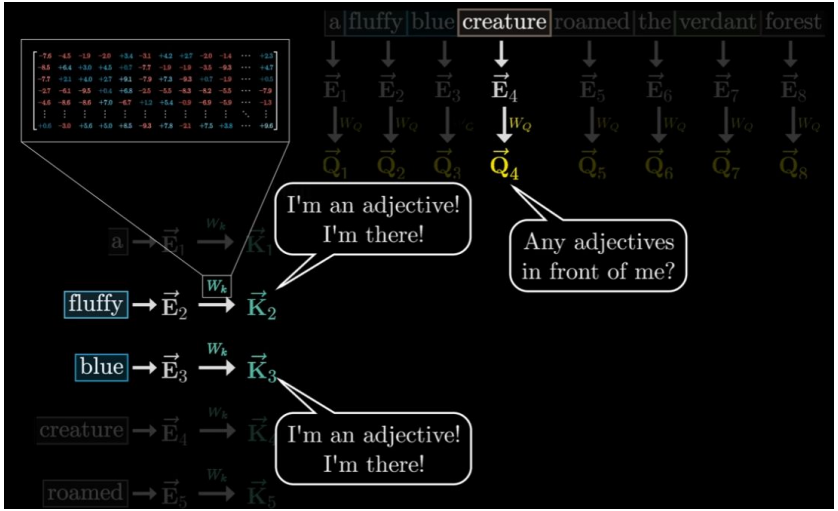

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Self-attention mechanism

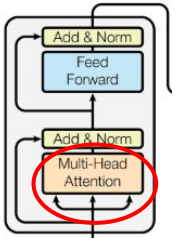

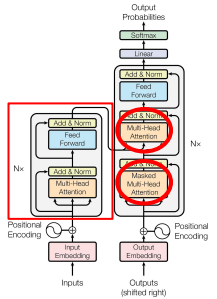

- Attention possui três componentes: Q, K e V
  - (Q)uery
  - (K)ey: Representa a “chave” que um token usa para responder às queries
  - (V)alue

Queries e Keys definem um “espaço de similaridade” onde tokens com queries e keys alinhadas terão alta atenção

Essa similaridade é medida pelo dot product entre cada vetor Ki e Qi

Maiores valores indicam maior similaridade entre pares (query,key)

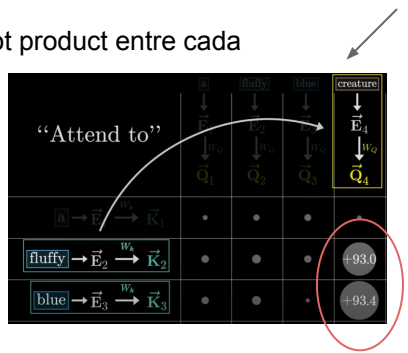

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Self-attention mechanism

- Attention possui três componentes: Q, K e V
  - (Q)uery
  - (K)ey
  - (V)alue: Contém a informação “real” que será propagada após a atenção ser calculada

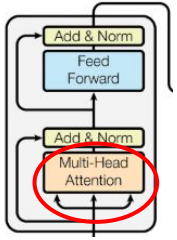

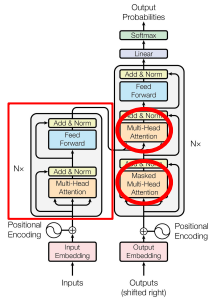

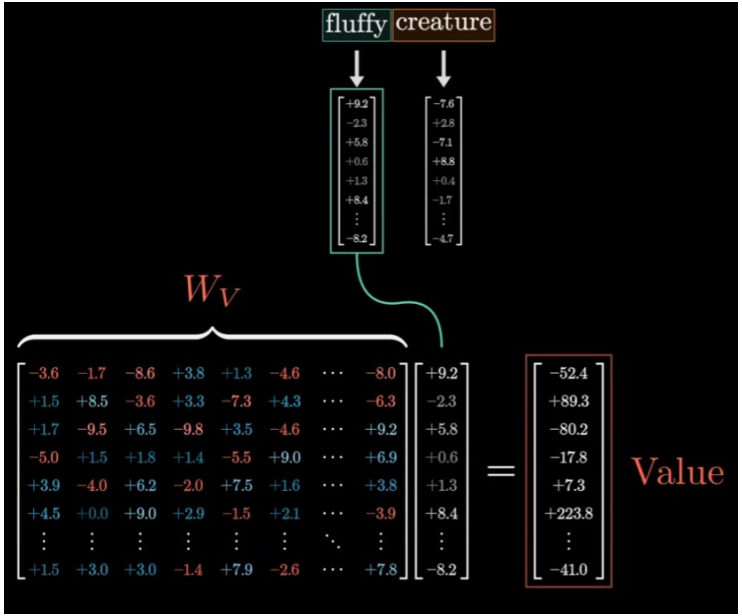

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Self-attention mechanism

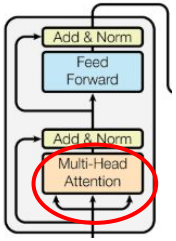

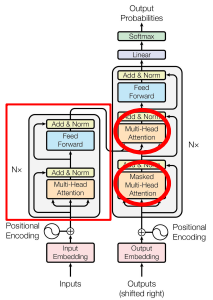

- Attention possui três componentes: Q, K e V
  - (Q)uery
  - (K)ey
  - (V)alue: Contém a informação “real” que será propagada após a atenção ser calculada

É responsável por carregar a informação do valor real (embeddings originais), que foi “perdida” pela atenção em QK

A informação dos embeddings Ei é multiplicada por cada vetor Vi, contendo seu “peso de origem”

Estas alterações são somadas aos vetores originais

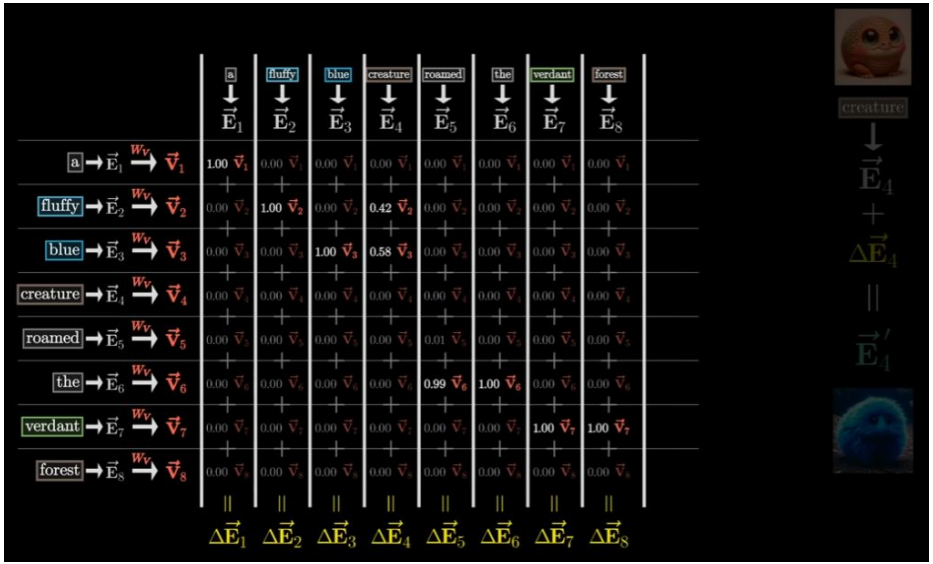

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{K^T Q}{\sqrt{d_k}}\right) V$$

Self-attention vs. cross-attention

- Self-attention:
  - Captura relações internas do texto, aprendendo dependências sintáticas e semânticas dentro da mesma frase
  - Q, K e V vêm da mesma sequência (texto de entrada)

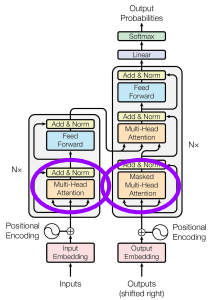

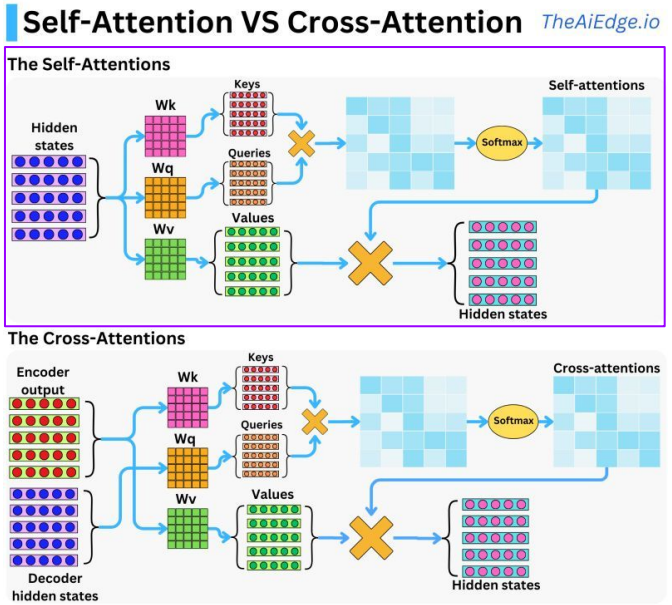

https://www.linkedin.com/posts/damienbenveniste_what-is-the-difference-between-self-attention-activity-7211029906166624257-m0Wn

Self-attention vs. cross-attention

- Self-attention:
  - Captura relações internas do texto, aprendendo dependências sintáticas e semânticas dentro da mesma frase
  - Q, K e V vêm da mesma sequência (texto de entrada)

- Cross-attention:
  - Permite que o Decoder foque nas partes relevantes da entrada
  - Usado na 2a camada do Decoder
  - K e V vêm do encoder
  - Q vem do decoder

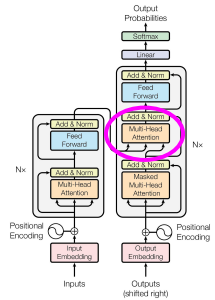

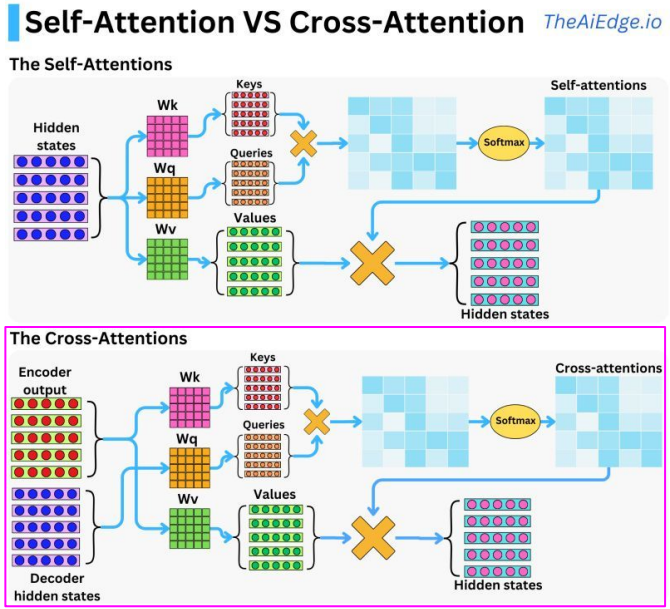

https://www.linkedin.com/posts/damienbenveniste_what-is-the-difference-between-self-attention-activity-7211029906166624257-m0Wn

Masked attention

- Utilizado no Decoder para garantir que a geração de sequências seja autoregressiva (ou seja, o contexto só deve depender do “passado”)
- Aplica uma máscara para que parte do mecanismo de atenção de cada palavra “do futuro” não seja usado (softmax = 0)

Exemplo:

“O gato <?> feliz”.

Previsão de <?> deve levar em conta apenas “O gato”

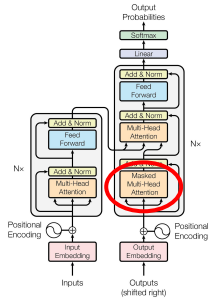

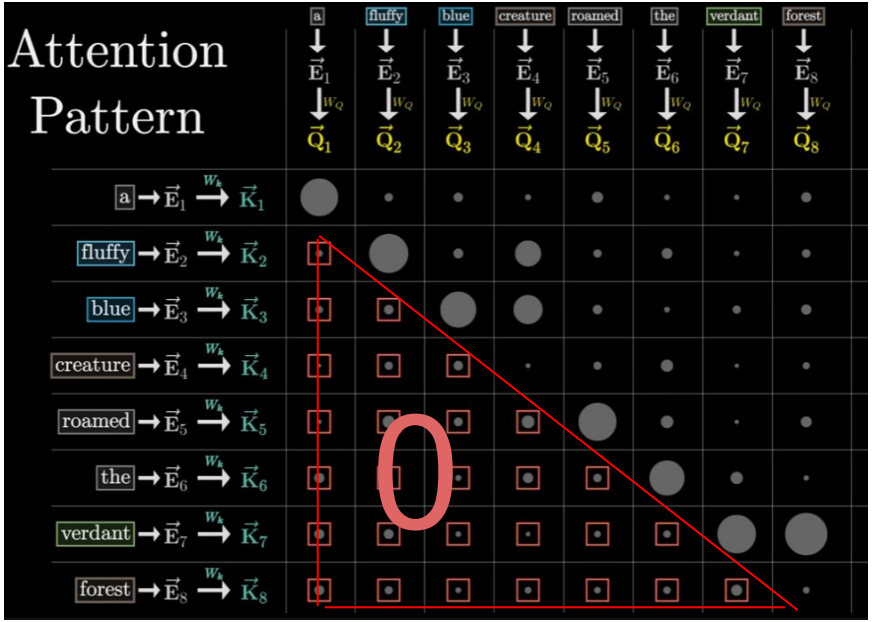

Tamanho do contexto

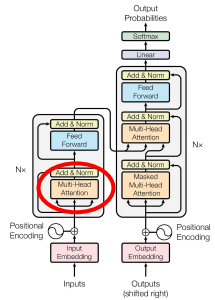

- Contexto é o número máximo de tokens que o modelo pode processar em uma sequência
- Tamanho da matriz de atenção é igual ao quadrado do tamanho do contexto C
- A matriz de atenção tem tamanho C x C
- Se o número de tokens permitidos de entrada é 2048, a matriz é 2048 x 2048 = 4.194.304
- GPT-1: 512 tokens GPT-2: 1024 tokens
  GPT-3: 2048 tokens GPT-4: 32k tokens

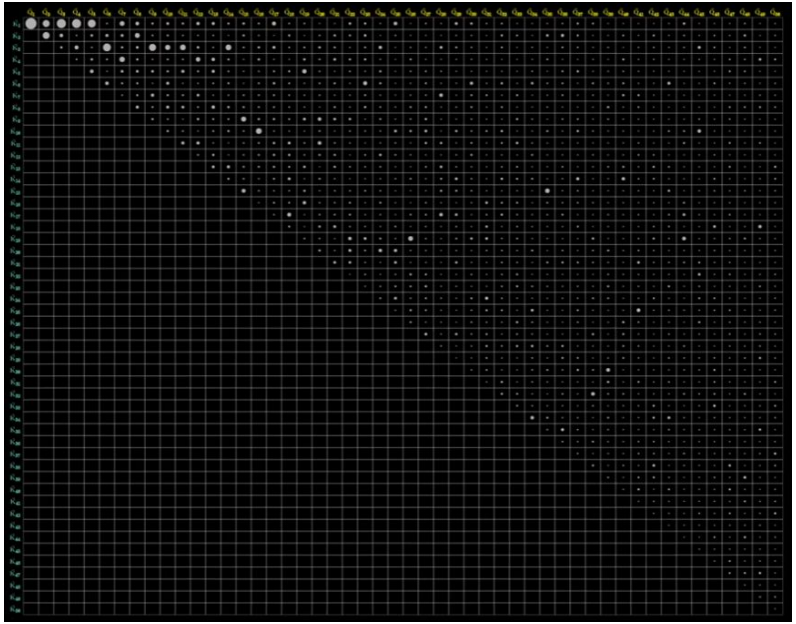

Multi headed attention

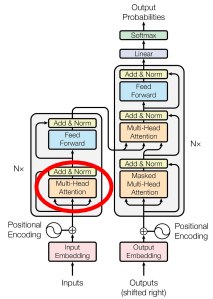

- Permite que o modelo capture diferentes tipos de relações (sintáticas, semânticas, locais/globais) em paralelo
  - Cada matriz attention possui seus próprios pesos Q, K, V
  - Ideia é capturar diferentes aspectos focando em relações não óbvias (uma para sujeito-verbo, outra para adjetivo-substantivo, outra para longo alcance, etc.)

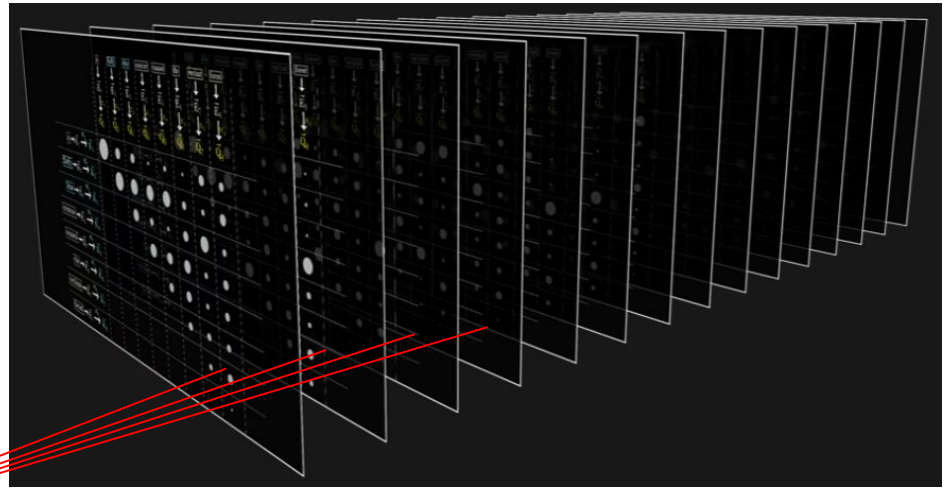

Multi headed attention

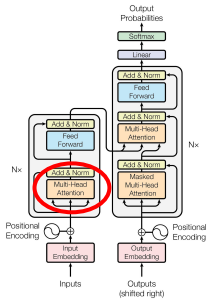

- Permite que o modelo capture diferentes tipos de relações (sintáticas, semânticas, locais/globais) em paralelo
  - Cada matriz attention possui seus próprios pesos Q, K, V
  - Ideia é capturar diferentes aspectos focando em relações não óbvias (uma para sujeito-verbo, outra para adjetivo-substantivo, outra para longo alcance, etc.)

- Cada embedding “novo” de cada token de entrada é dado pela soma de todos os valores encontrados em cada cabeça

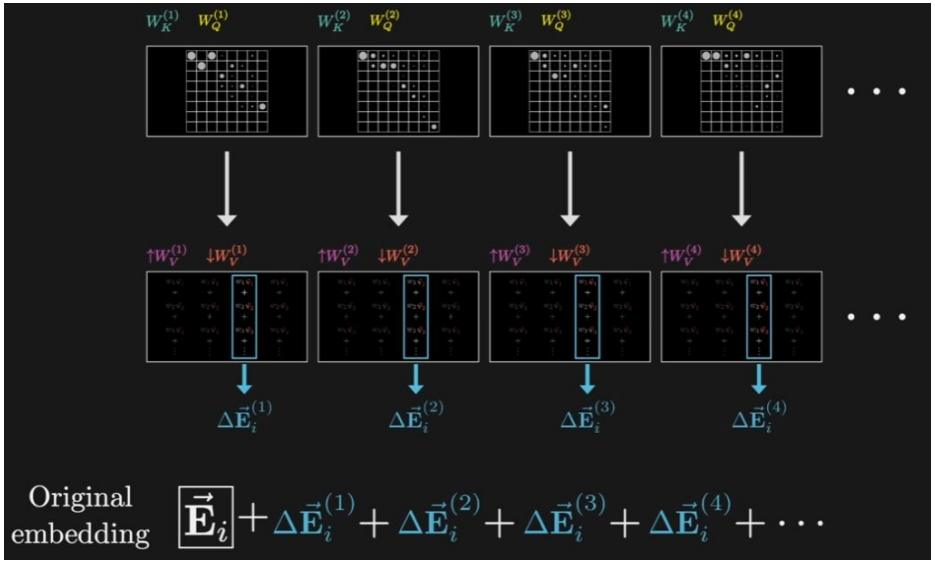

Residual connections

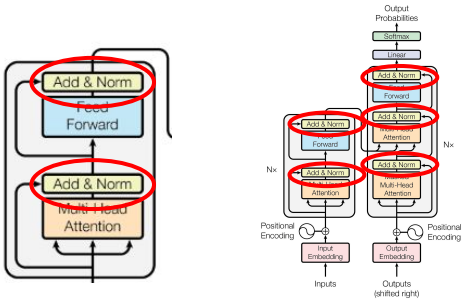

- Atalhos em uma rede neural que conectam a saída de uma camada diretamente à saída de uma camada mais à frente, "saltando" uma ou mais camadas intermediárias

- Ajudam a mitigar o problema do *vanishing gradient* (valores próximos de zero)
  - Preservam o sinal durante a retropropagação
  - Garantem que a representação contextual dos tokens mantenha uma conexão com seu estado original

- São agregados com soma e normalização (add & norm)

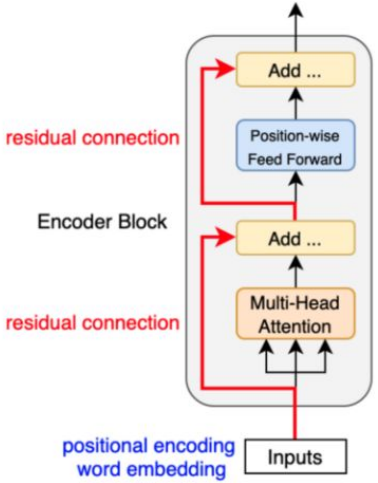

Mais detalhes em: https://stats.stackexchange.com/questions/565196/why-are-residual-connections-needed-in-transformer-architectures

Feedforward

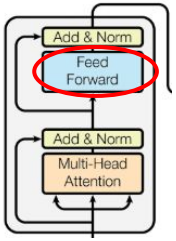

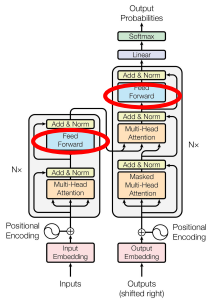

- Rede neural fully-connected (MLP) “padrão” de deep learning
- Aplicada independentemente a cada posição (token) da sequência (não considera os vizinhos)
- Utiliza função de ativação ReLU

ReLU

$$\max(0, x)$$

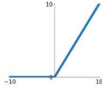

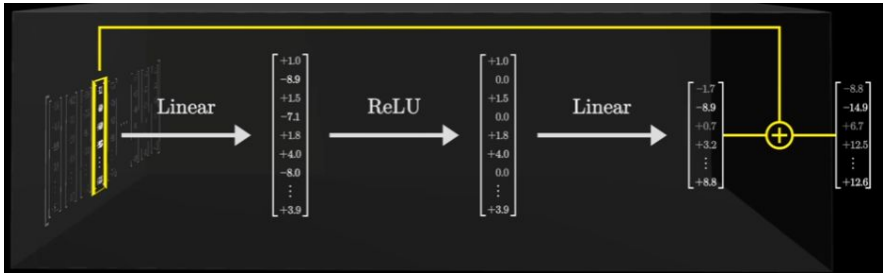

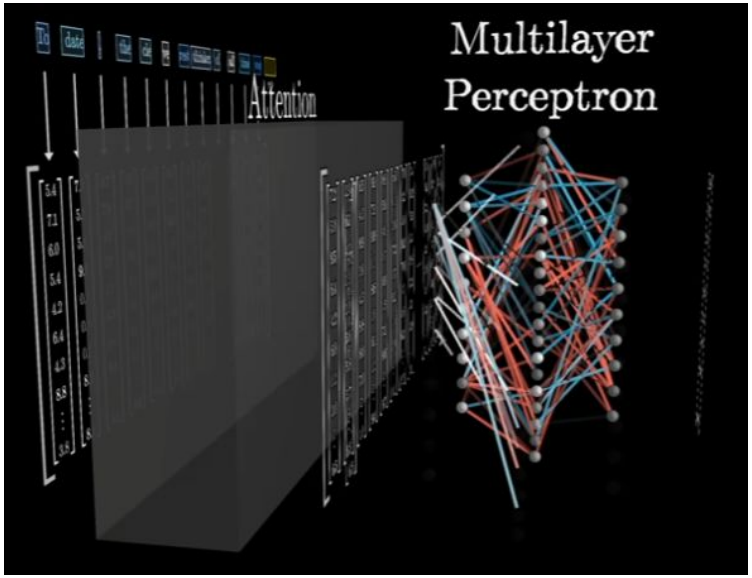

Linear + softmax + output

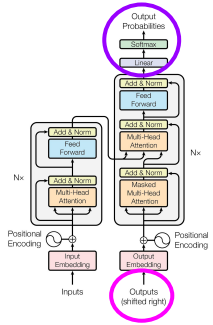

- Linear: camada que transforma o embedding de cada token um valor (número) chamado de logit
- Cada logit não tem um significado direto isolado, mas quando comparado com os demais, quanto maior o logit, maior a chance daquela palavra ser escolhida
- Os logits são transformados em valores no intervalo [0,1] pela função softmax, indicando “probabilidades” (output probabilities) [Output probabilities]
- Encoder é aplicado 1x e decoder Nx (a cada vez a entrada no outputs é deslocada) [Output shifted right]

$$\text{output} = x \cdot W^T + b$$

Exemplo:

Vocabulário |V| = 10.000 tokens
Embedding |Ei| = 512

Matriz de embeddings: $E_{\text{input}} \in \mathbb{R}^{10.000 \times 512}$

Matriz de pesos: $W \in \mathbb{R}^{10.000 \times 512}$ → Transposta!

Logits: $\text{logits} \in \mathbb{R}^{10.000}$ → Aleatória e ajustada por backpropagation

Exemplo (tradução automática)

- Para cada “frase” (texto):
  - Encoder:
    - Input: I love books

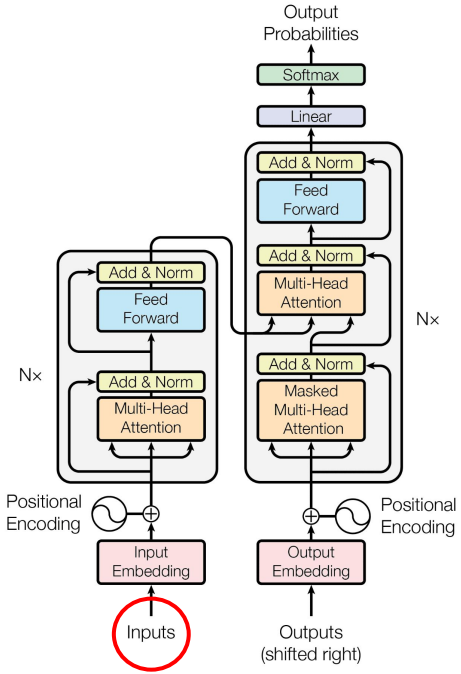

Exemplo (tradução automática)

- Para cada “frase” (texto):
  - Encoder:
    - Input: I love books
    - Output:
      I: [0.1, 1.3, 6.4, -4.5 … 3.2] (dimensão 512)
      love: [0.4, 5.3, 0.4, -1.5 … 7.1] (dimensão 512)
      books: [1.0, 2.3, 1.4, -7.5 … 4.2] (dimensão 512)

Este passo ocorre uma única vez antes do “decoder”

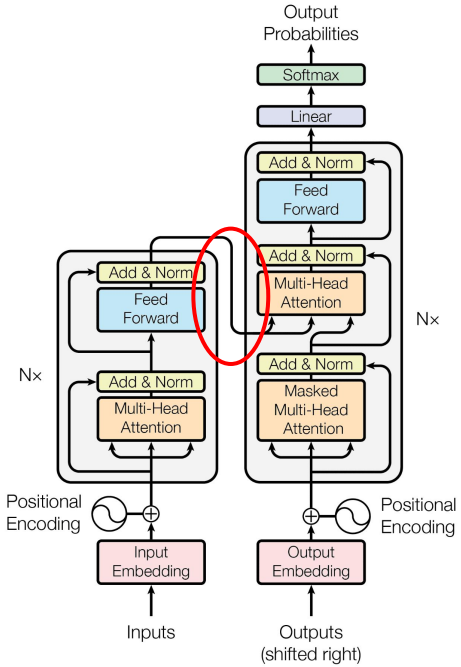

Exemplo (tradução automática)

- Para cada “frase” (texto):
  - Encoder:
    - Input: I love books
    - Output:
      I: [0.1, 1.3, 6.4, -4.5 … 3.2] (dimensão 512)
      love: [0.4, 5.3, 0.4, -1.5 … 7.1] (dimensão 512)
      books: [1.0, 2.3, 1.4, -7.5 … 4.2] (dimensão 512)
  - Decoder (t=1):
    - Input: [<s>]
    - Output:
      Eu: 0.1
      amo: 0.6
      livros: 0.2
      …

Objetivo é prever o próximo após <s>, ou seja, Eu

Errou!
Cálculo da loss (o correto era Eu com 1.0)
Loss(t1) = 0.9

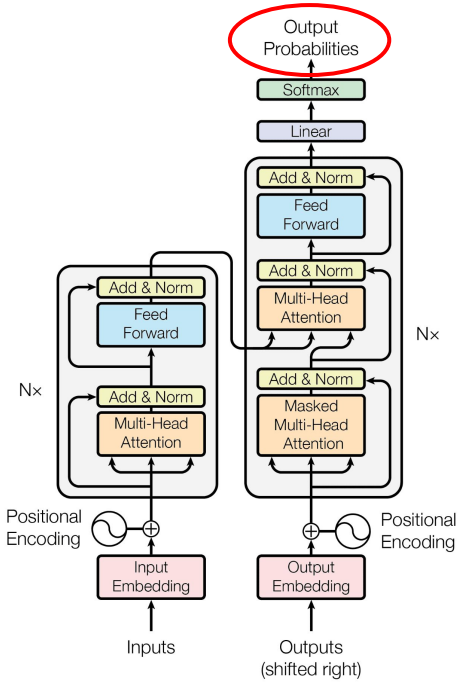

Exemplo (tradução automática)

- Para cada “frase” (texto):
  - Encoder:
    - Input: I love books
    - Output:
      I: [0.1, 1.3, 6.4, -4.5 … 3.2] (dimensão 512)
      love: [0.4, 5.3, 0.4, -1.5 … 7.1] (dimensão 512)
      books: [1.0, 2.3, 1.4, -7.5 … 4.2] (dimensão 512)
  - Decoder (t=2):
    - Input: [<s>,Eu]
    - Output:
      Eu: 0.1
      amo: 0.2
      livros: 0.3
      …

Errou!
Cálculo da loss (o correto era amo com 1.0)
Loss(t1) = 0.9
Loss(t2) = 0.8

Objetivo é prever o próximo após Eu, ou seja, amo

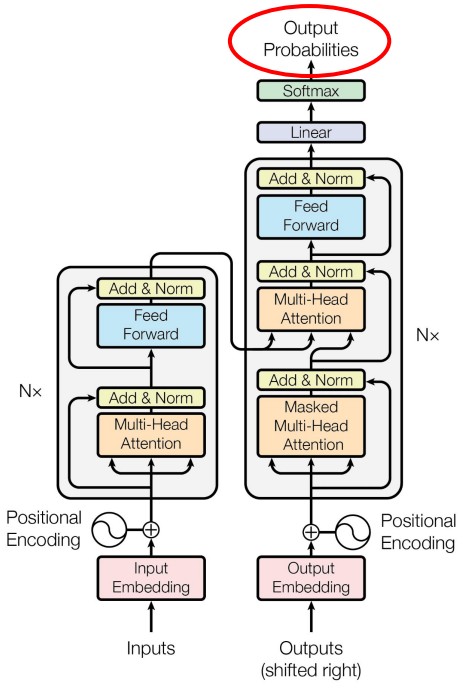

Exemplo (tradução automática)

- Para cada “frase” (texto):
  - Encoder:
    - Input: I love books
    - Output:
      I: [0.1, 1.3, 6.4, -4.5 … 3.2] (dimensão 512)
      love: [0.4, 5.3, 0.4, -1.5 … 7.1] (dimensão 512)
      books: [1.0, 2.3, 1.4, -7.5 … 4.2] (dimensão 512)
  - Decoder (t=T):
    - Input: [<s>,Eu]
    - Output:
      Eu: 0.1
      amo: 0.2
      livros: 0.3
      …

Errou!
Cálculo da loss (o correto era amo com 1.0)
Loss(t1) = 0.9
Loss(t2) = 0.8
…

Loss total (soma ou média por token)
Backpropagation: calcula o gradiente da loss total, propaga os erros por todas as camadas

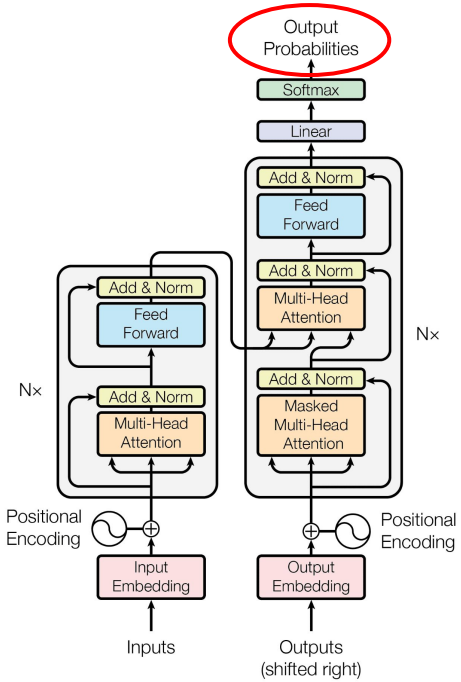

Transformers

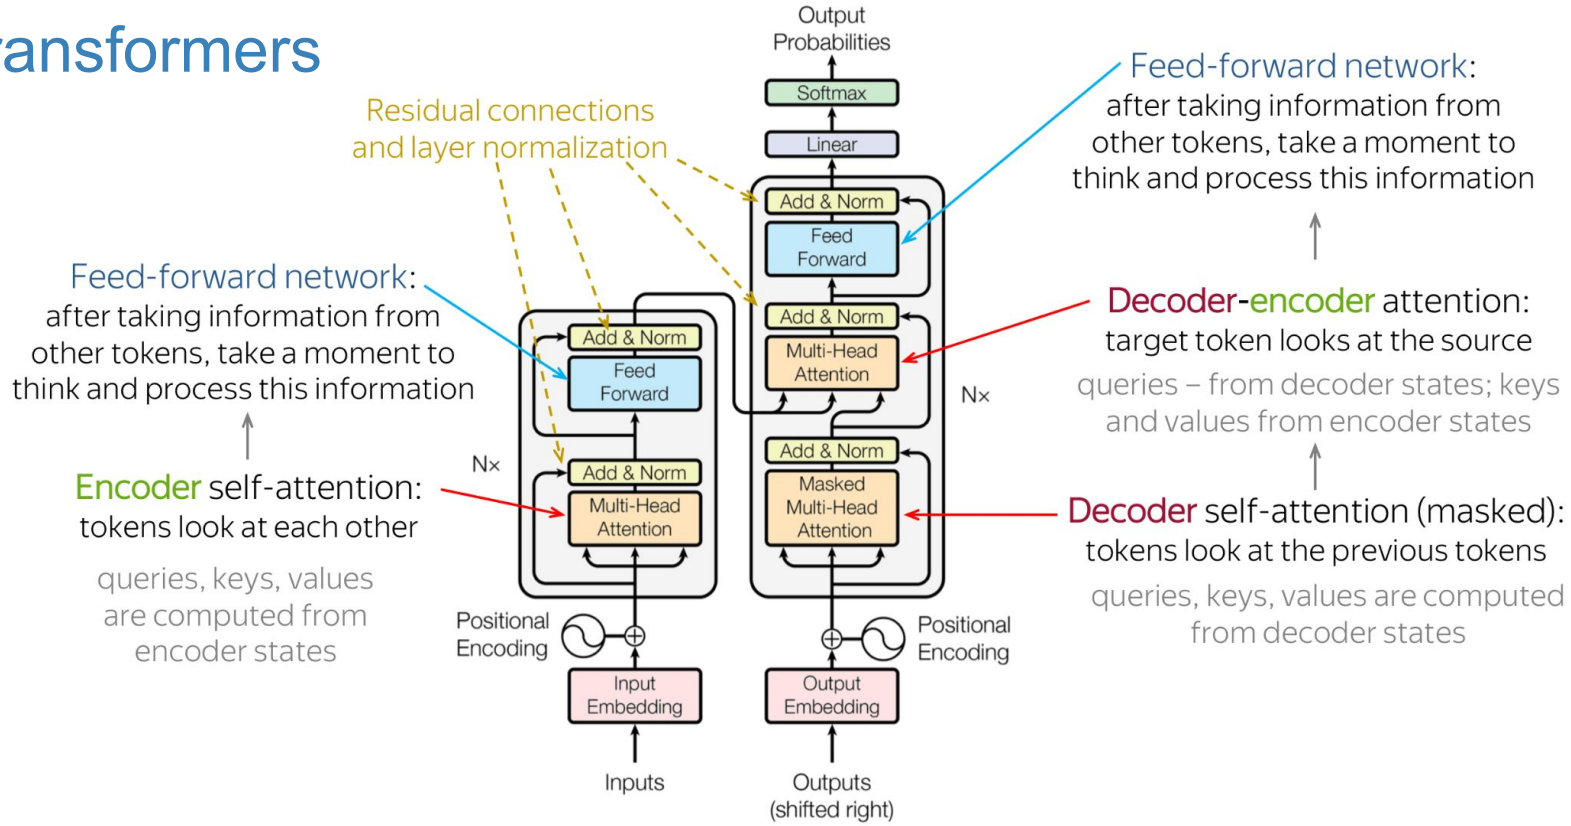

Referências

- Understanding Transformers
  - https://www.analyticsvidhya.com/blog/2019/06/understanding-transformers-nlp-state-of-the-art-models/
- The illustrated Transformer
  - https://jalammar.github.io/illustrated-transformer/
- Canal StatQuest (YouTube): https://www.youtube.com/@statquest
- Canal 3Blue1Brown (YouTube): https://www.youtube.com/@3blue1brown

Próximas aulas

- Large Language Models [1]
  - Encoder-only (de compreensão - NLU)

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
Instituto de Informática
Departamento de Informática Aplicada

Obrigado pela atenção!
Dúvidas?

Prof. Dennis Giovani Balreira
(Material adaptado da Profa. Viviane Moreira e dos canais StatQuest e 3Blue1Brown)

UFRGS
UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL

INF01221 - Tópicos Especiais em Computação XXXVI:
Processamento de Linguagem Natural

.inf
INSTITUTO DE INFORMÁTICA
UFRGS